

정치 기사 코퍼스를 활용한 제21대 대선 주요 후보의 언론 묘사 경향 분석 및 대선 결과 예측

5조

디지털경영학과 2019390711 노형래

언어학과 2019131603 민혜린

국어국문학과 2024130011 추소영

Zhang Mei

목차

1. 연구 주제 선정 배경

2. 선행 연구 검토

3. 연구 방법

4. 연구 수행

- 1) 데이터 수집 (+튜토리얼)
- 2) 데이터 전처리
- 3) TF 및 TF-IDF 분석 및 코사인 유사도
- 4) 워드임베딩 클러스터 분석

5. 분석 결과 요약

6. 결론

- 1) 요약
- 2) 의의 및 함의
- 3) 한계 및 향후 과제

7. 참고 문헌

1. 연구 주제 선정 배경

현대 정치 환경에서 언론은 후보자에 대한 정보를 구성하고 유통하는 핵심 매체다.

특히 대선과 같은 정치적 전환기에는 언론 보도에 나타나는 주요 키워드와 의미 구조가 후보자의 당선 가능성을 예측하는 데 중요한 단서가 될 수 있다.

하지만 기존 연구들은 언론의 정치적 성향에 따른 프레이밍 전략이나 정당성 부여 방식에 초점을 맞춘 경우가 많으며, 언론이 형성한 담론 구조가 당선 결과와의 연관성을 정량적으로 분석한 시도는 상대적으로 부족하다.

따라서 2025년 제21대 대선과 관련하여, 언론에서 각 후보자에게 구성된 주류 담론(대표 키워드, 의미군집)을 텍스트 마이닝 기반으로 분석하고, 이를 통해 후보자의 이미지 구조 및 담론을 파악함으로써, 언론 담론 및 언어가 당선 가능성 예측에 어떻게 기여할 수 있는지 탐색한다.

2. 선행 연구 검토

OECD 통계는 우리 사회와의 비교 잣대로 어떻게 활용되고 있는가: OECD가 인용된 언론보도에 대한 텍스트 마이닝 분석 (양혜승, 양수연)

한국 언론이 OECD 통계를 어떻게 활용하고 있는지를 텍스트 마이닝 기법으로 분석
언론의 정치적 성향(보수 vs 진보) 및 시대별 정부 맥락에 따라 OECD 통계 인용 방식이 어떻게 달라지는지 규명

OECD 통계가 객관적 기준이 아닌 정치적, 언론적 프레임에 따라 유동적으로 인용한다.

한국 언론은 어떻게 신생 대통령 권력을 정당화하는가: 막스 베버 정치지도자론과 텍스트 마이닝 분석 (이한준)

대통령 당선 직후 언론이 신생 권력을 어떻게 보도하며, 어떤 방식으로 정당화하는지를 분석
막스 베버의 지배 정당성 이론(전통·합법·카리스마적 지배)을 한국 언론보도 분석에 적용

언론은 단순 정보 전달을 넘어서 신생 권력에 대해 프레임을 설정하고 정당성을 부여하는 행위자 → 정권교체기 언론의 역할은 민주주의 정당성에 중대한 영향을 미칠 수 있음

언론 보도에 나타난 주요 키워드와 보도 경향을 텍스트 마이닝으로 분석
→ 반복적으로 언급되는 단어와 묘사 양상을 통해 정치인별 이미지 구성 양상 파악

3. 연구 방법

1) 데이터 수집

- 주요 대선 후보 3인 선정
(이재명, 김문수, 이준석)
- 해당 정치인 언급 기사 1,000건 수집

2) TF 및 TF-IDF, 코사인 유사도 분석

- TF: 단어 빈도
- TF-IDF: 역문헌 기반 가중 빈도값
- TF-IDF 기반 코사인 유사도 분석

3) 워드임베딩 분석

- Word2Vec 학습 키워드 추출
- 의미적 결속력 분석
- Word2Vec기반 클러스터링

4. 연구 진행

4. 연구 진행

1) 데이터 수집 + 튜토리얼

4. 연구 진행

1) 데이터 수집

A. 데이터 선정 기준

- 기간: 사전 투표 전날(5/28)을 최신으로 1,000건 → 출구 조사 등에 영향을 받지 않기 위함
- 인물: 대표 대선 후보 3인 (이재명, 김문수, 이준석)
- 출처: 네이버 뉴스 크롤링, 주요 언론사를 출처로 하되 정치적 성향을 고려하여 균형을 맞춤
→ 조선일보, 중앙일보, 동아일보 / 경향신문, 한겨레신문, 오마이뉴스

4. 연구 진행

1) 데이터 수집

B. 기사 크롤링

```
from datetime import datetime, timedelta
from selenium import webdriver
from selenium.webdriver.chrome.options import Options
from selenium.webdriver.common.by import By
import time
```

```
from utils import *
```

```
import os
import json
from datetime import datetime
```

```
# 기본 설정
names = ['이재명', '김문수', '이준석']
press_code = {
    .... '경향신문': '1032',
    .... '동아일보': '1020',
    .... '오마이뉴스': '1047',
    .... '조선일보': '1023',
    .... '중앙일보': '1025',
    .... '한겨레신문': '1028'
}
```

```
# 날짜 설정
start_date = datetime(2025, 5, 1)
end_date = datetime(2025, 5, 28)
```

외부 모듈 및 라이브러리 импорт

Selenium: 웹 브라우저를 자동으로 조작할 수 있게 해주는 프레임워크

검색 대상 설정 (이재명, 김문수, 이준석)

네이버 뉴스 검색에서 대상 언론사들만 필터링하여 보기 위해 필요한 언론사 고유 코드

기간 설정: 5월 28일(사전투표일 직전 날짜)를 최신으로 함
(5월 1일: 임의로 설정한 시작 날짜)

4. 연구 진행

(+) 데이터 수집 튜토리얼

튜토리얼 파일 링크

https://github.com/hyeriiiinnnn/KORE208_team5/tree/main/tutorial

* '/tutorial'에 있는 폴더, 파일 모두 다운로드 해야 실행됩니다!



4. 연구 진행

1) 데이터 수집

 김문수.json

 이재명.json

 이준석.json

<pre>{ "id": "이재명_한겨레신문_20250528_1794", "order": 1, "title": "이재명 “기후에너지부 신설·기재부 개편”…김문수 “규제혁신처 신설””, "press": "한겨레신문", "date": "2025.05.28. 오후 10:30", "content": "이재명, 기재부 예산 기능 분리·성명등가족부 개편김문수, 인구청년가족부 신설…“여가부 현상 유지”\n\n\n\n이재명·더불어민주당·권영국 민주노동당 김문수 국민의힘·이준석 개혁신당 대선 후보가 27일 서울 마포구 삼암동 엠비시(MBC) 스튜디오에서 진행된 정치 분야 티브이(TV)토론회에 앞서 포즈를 취하고 있다. 연합뉴스21대 "source": "https://n.news.naver.com/mnews/article/028/0002748264?sid=154" }, { "id": "이재명_조선일보_20250528_1210", "order": 2, "title": "이재명 43~48%, 김문수 34~36%, 이준석 10~12%", "press": "조선일보", "date": "2025.05.28. 오후 10:12", "content": "이재명 43% 김문수 36% 이준석 11% [코리아리서치·MBC] 이재명 48% 김문수 34% 이준석 10% [입소스·SBS] 이재명 48% 김문수 35% 이준석 12% [메타보이스·JTBC] \n\n\n\n(원쪽부터) 이재명 더불어민주당 후보, 김문수 국민의힘 후보, 이 "source": "https://n.news.naver.com/mnews/article/023/0003907915?sid=154" }, { "id": "이재명_한겨레신문_20250528_1797", "order": 3, "title": "“여성혐오 발언’ 이준석, 경찰 고발·윤리위 제소에도 “이재명 사과하라””, "press": "한겨레신문", "date": "2025.05.28. 오후 10:12", "content": "윤리위 제소에 ‘여성정당 같은 정당…갈장아사’ 범죄일람표 게시 뒤 “이재명 사과 기대한다”\n\n\n\n\n이준석 개혁신당 대통령 후보가 28일 서울 마포구 삼암동 엠비시(MBC) 스튜디오에서 진행된 정치 분야 티브이(TV)토론회에 앞서 포즈를 취하고 있다. 연합뉴스21대 "source": "https://n.news.naver.com/mnews/article/028/0002748260?sid=154" }, { "id": "이재명_경향신문_20250528_341", "order": 4, "title": "책임 막중한진 국가 복지…이재명 “보편” 김문수 “선별”[21대 대선 공약 검증]", "press": "경향신문", "date": "2025.05.28. 오후 9:23", "content": "☞ 보건·복지\n\n\n\n\n복지 - 연금, 저출생·고령화이재명, 연금 보완·아동수당 확대김문수, 2차 개혁·주거비 차등 지원이준석, 신연금…권영국, 특히 편입연금안 놓고 세대별 강조점 차이 입신·출생·간병비 등 인구대책재정 지원 확대 공통, "source": "https://n.news.naver.com/mnews/article/032/0003372704?sid=102" }, { "id": "이재명_경향신문_20250528_346", "order": 5, "title": "동부권 한강벨트 품며 “내란 심판”…유류브선 “가족과 싸움 가장 후회””, "press": "경향신문", "date": "2025.05.28. 오후 9:13", "content": "이재명 더불어민주당 대선 후보가 사전투표를 하루 앞둔 28일 수도권 최대 격전지인 ‘한강 벨트’를 찾아 “‘윤석열 아바타’를 통해 내란 "source": "https://n.news.naver.com/mnews/article/032/0003372697?sid=100" }, { "id": "이재명_경향신문_20250528_340", "order": 6, "title": "마지막 여론조사도 ‘반전’ 없었다…김문수·이준석 단일화 가정해도 이재명 ‘우위’”, "press": "경향신문", "date": "2025.05.28. 오후 9:05", "content": "이재명, 오차범위 밖 김문수 앞서\n\n\n\n\n단일화 시 한국리서치 1곳만이 44%·김 41% ‘오차범위’6·3 대통령 선거 여론조사 공표금지 조 "source": "https://n.news.naver.com/mnews/article/032/0003372689?sid=154" }, { "id": "이재명_동아일보_20250528_638", "order": 7, "title": "이재명 “정부가 기본 역할 안 해 경제 말라죽어…추경부터 해야””, "press": "동아일보", "date": "2025.05.28. 오후 9:03", "content": "더불어민주당 이재명 대통령 후보가 28일 서울 황신리역 광장에서 열린 성동구·동대문구 집중 유세에서 연설을 마친 뒤 시민들을 향해 인사하고 있다. (공동취재) 2025.5.28더불어민주당 이재명 대선 후보가 집권하게 된다면 가장 서울러 할 일로 ‘추경’을 꼽았다.이 후보는 28일 오후 7시 40분 MBC라디오 ‘권순표의 뉴스하이킹’ "source": "https://n.news.naver.com/mnews/article/028/0002748264?sid=154" }, { "id": "김문수_한겨레신문_20250528_3527", "order": 1, "title": "이재명 “기후에너지부 신설·기재부 개편”…김문수 “규제혁신처 신설””, "press": "한겨레신문", "date": "2025.05.28. 오후 10:30", "content": "이재명, 기재부 예산 기능 분리·성명등가족부 개편김문수, 인구청년가족부 신설…“여가부 현상 유지”\n\n\n\n\n이재명·더불어민주당·권영국 민주노동당 김문수 국민의힘·이준석 개혁신당 대선 후보가 27일 서울 마포구 삼암동 엠비시(MBC) 스 "source": "https://n.news.naver.com/mnews/article/028/0002748264?sid=154" }, { "id": "김문수_조선일보_20250528_2948", "order": 2, "title": "이재명 43~48%, 김문수 34~36%, 이준석 10~12%", "press": "조선일보", "date": "2025.05.28. 오후 10:12", "content": "이재명 43% 김문수 36% 이준석 11% [코리아리서치·MBC] 이재명 48% 김문수 34% 이준석 10% [입소스·SBS] 이재명 48% 김문수 35% 이준석 12% [메타보이스·JTBC] \n\n\n\n\n(왼쪽부터) 이재명 더불어민주당 후보, 김문수 국민의힘 후보, 이 "source": "https://n.news.naver.com/mnews/article/023/0003907915?sid=154" }, { "id": "김문수_오마이뉴스_20250528_2679", "order": 3, "title": "대구 간 김문수 \“박근혜와 같은 학년·학교, 의원도 같이 해””, "press": "오마이뉴스", "date": "2025.05.28. 오후 9:53", "content": "“박근혜 인연 강조하며 지지 호소, 이재명 더불어민주당 후보엔 ‘도돌이표’ 비난\n\n\n\n\n▲ 김문수 국민의힘 대선 후보가 28일 오후 대구 중구 동성로에서 열린 집중유세에 참석해 지지를 호소하고 있다.© 조정훈제21대 대통령선거 사전투 "source": "https://n.news.naver.com/mnews/article/047/0002475281?sid=100" }, { "id": "김문수_오마이뉴스_20250528_2680", "order": 4, "title": "[영상] 유영하 \“박근혜 대통령 뵙고 싶죠? 김문수 뽀아달라””, "press": "오마이뉴스", "date": "2025.05.28. 오후 9:39", "content": "▲ [오마이포토] 유영하 “박근혜 뵙고 싶죠… 김문수 뽀아달라” © 유성호유영하 국민의힘 의원이 28일 오후 대구 중구 아트스퀘어 앞에서 열린 김문수 국민의힘 대선 후보 ‘필승으로 이어질, 대구의 합성’ 집중유세에 참석해 김 후보의 손 "source": "https://n.news.naver.com/mnews/article/047/0002475278?sid=100" }, { "id": "김문수_경향신문_20250528_2131", "order": 5, "title": "책임 막중한진 국가 복지…이재명 “보편” 김문수 “선별”[21대 대선 공약 검증]", "press": "경향신문", "date": "2025.05.28. 오후 9:23", "content": "☞ 보건·복지\n\n\n\n\n복지 - 연금, 저출생·고령화이재명, 연금 보완·아동수당 확대김문수, 2차 개혁·주거비 차등 지원이준석, 신연금…권영국, 특히 편입연금안 놓고 세대별 강조점 차이 입신·출생·간병비 등 인구대책재정 지원 확대 공통, "source": "https://n.news.naver.com/mnews/article/032/0003372704?sid=102" }, }</pre>	
---	--

4. 연구 진행

2) 데이터 전처리

2) 데이터 전처리

A. 형태소 분석기 선택 - Mecab

- 사전 기반 + CRF(통계적 모델)
- 기본 명사/ 동사 중심 분할
- 처음 보는 단어에 대해서는 품사 태깅을 잘게 하는 경향이 있음

예시 문장

“김문수 후보는 단일화를 추진하고 있다”

분석결과

김문수(NNP) 후보(NNG) 는(JX) 단일화(NNG) 를(JKO) 추진(NNG) 하고(XSV+EC) 있다(EC)



Mecab은 “추진”을 명사로 처리하고, “하고 있다”를 어절 단위로 분석해 문장의 의미 흐름 충분히 반영 X

4. 연구 진행

2) 데이터 전처리

A. 형태소 분석기 선택 - Kiwi

- 딥러닝 기반 한국어 특화
- 복합어 분석 우수
- 사용자 단어 추가 기능

Ex) 더불어민주당, 국민의 힘, 개혁신당을 하나의 명사로 품사 태깅

예시 문장

“김문수 후보는 단일화를 추진하고 있다”

분석결과

김문수(NNP) 후보(NNG) 는(JX) 단일화(NNG) 를(JKO) 추진(VV) 하(XSV) 고(EC) 있(VX) 다(EF)



Kiwi는 “추진”을 **동사**로 처리하고, “하고 있다” 세분화하여 품사태깅 하여 문맥을 반영하여 토큰화

4. 연구 진행

2) 데이터 전처리

B. 정규표현식 활용 전처리 (공통)

```
def clean_text(text):  
    text = re.sub(r'<.*?>', '', text)  
    text = re.sub(r'\n+', ' ', text)  
    text = re.sub(r'["\'!?,;: \(\) \[ \] \{ \} ]', '', text)  
    text = re.sub(r'^\w\s가-힣$', '', text)  
    text = re.sub(r'\s+', ' ', text).strip()  
    return text
```

HTML 태그 제거

줄바꿈 > 공백

주요 문장부호 제거

특수문자 제거 (이중 필터링)

다중 공백 제거

4. 연구 진행

2) 데이터 전처리

C. 사용자 단어 사전 등록 및 불용어 제거 품사 정의- 이재명

```
# 5. 불용어 및 제거 품사 정의
```

```
stopwords = set([
    "것", "수", "등", "더", "때", "자신", "이번", "이후", "위해", "관련",
    "의견", "최근", "대해", "내용", "경우", "부분", "정도", "현재", "상황",
    "사실", "또한", "통해", "가장", "대한", "전혀", "하나", "바로", "계속",
    "여러", "많은", "이미", "이", "그", "저", "우리", "그것", "이것"
])
```

```
stop_tags = {
    'JKS', 'JKC', 'JKG', 'JKB', 'JKO', 'JKV',
    'JX', 'JC',
    'NNB',
    'NR', 'SN',
    'SF', 'SP', 'SS', 'SE', 'SO',
    'EP', 'EF', 'EC', 'ETN', 'ETM',
    'XPN', 'XSN', 'XSV', 'XSA',
    'IC',
    'SF', 'SE', 'SS', 'SP', 'SO',
    'VSV', 'NR'
}
```

```
# 4. 형태소 분석기 초기화 및 사용자 단어 등록
```

```
kiwi = Kiwi()
user_words = ['개혁신당', '더불어민주당', '국민의힘', '최고득표율',
              '이 후보', '인공지능', '직권남용', '양자대결',
              '김 후보', '출구조사', '선거법', '더준플',
              '권영국', '어대명', '방사능', '당시엔']
for word in user_words:
    kiwi.add_user_word(word, 'NNP', 0)
```


4. 연구 진행

2) 데이터 전처리

C. 사용자 단어 사전 등록 및 불용어 제거 품사 정의- 김문수

```
# 5. 불용어 및 제거 품사 정의
```

```
stopwords = set([
    "것", "수", "들", "더", "때", "자신", "이번", "이후", "위해", "관련",
    "의견", "최근", "대해", "내용", "경우", "부분", "정도", "현재", "상황",
    "사실", "또한", "통해", "가장", "대한", "전혀", "하나", "바로", "계속",
    "여러", "많은", "이미", "이", "그", "저", "우리", "그것", "이것"
])

stop_tags = {
    'JKS', 'JKC', 'JKG', 'JKB', 'JKO', 'JKV',
    'JX', 'JC',
    'NNB',
    'NR', 'SN',
    'SF', 'SP', 'SS', 'SE', 'SO',
    'EP', 'EF', 'EC', 'ETN', 'ETM',
    'XPN', 'XSN', 'XSV', 'XSA',
    'IC',
    'SF', 'SE', 'SS', 'SP', 'SO',
    'VSV', 'NR'
}
```

```
# 4. 형태소 분석기 초기화 및 사용자 단어 등록
```

```
kiwi = Kiwi()
user_words = ['개혁신당', '더불어민주당', '국민의힘', '최고득표율',
              '이 후보', '인공지능', '직권남용', '양자대결',
              '김 후보', '출구조사', '선거법', '더쭈플', '권영국', '김문수', '기차']

for word in user_words:
    kiwi.add_user_word(word, 'NNP', 0)
```

```
# 감탄사
```

```
# 기호
```

4. 연구 진행

2) 데이터 전처리

C. 사용자 단어 사전 등록 및 불용어 제거 품사 정의- 이준석

```
# 4. 분석에 의미 없는 단어 기반 불용어 리스트
```

```
stopwords = set([
    "것", "수", "등", "더", "때", "자신", "이번", "이후", "위해", "관련",
    "의견", "최근", "대해", "내용", "경우", "부분", "정도",
    "현재", "상황", "사실", "또한", "통해", "가장", "대한", "중요", "전혀",
    "하나", "바로", "계속", "여러", "많은", "이미", "그", "저", "우리", "그것", "이것"
])
```

```
# 5. 제거할 불필요한 품사 리스트
```

```
stop_tags = {
    'JKS', 'JKC', 'JKG', 'JKB', 'JKO', 'JKV',
    'JX', 'JC',
    'NNB',
    'NR', 'SN',
    'SF', 'SP', 'SS', 'SE', 'SO',
    'EP', 'EF', 'EC', 'ETN', 'ETM',
    'XPN', 'XSN', 'XSV', 'XSA',
    'IC',
    'SF', 'SE', 'SS', 'SP', 'SO',
    'VSV', 'NR'
}
```

```
# 형태소 분석기 초기화
```

```
kiwi = Kiwi()
```

```
# 사용자 정의 사전 추가
```

```
user_words = ['개혁신당', '더불어민주당', '국민의힘', '최고득표율',
               '이 후보', '인공지능', '직권남용', '양자대결',
               '김 후보', '출구조사', '선거법', '더쭈플', '권영국',
               '사고현장', '양회성']
```

```
for word in user_words:
```

```
    kiwi.add_user_word(word, 'NNP', 0)
```

4. 연구 진행

3) TF vs TF-IDF 분석

4. 연구 진행

3-1) TF 분석

```
# 불용어
custom_stopwords = ['후보', '대선', '대통령', '선거', '대하', '아니', '이날', '위하']
```

```
def remove_stopwords(text, stopwords):
    ... tokens = text.split()
    ... filtered_tokens = [t for t in tokens if t not in stopwords]
    ... return " ".join(filtered_tokens)
```

```
# 불용어 제거
corpus_tf = []
for name in names:
    ... cleaned_text = remove_stopwords(documents[name], custom_stopwords)
    ... corpus_tf.append(cleaned_text)
```

```
from sklearn.feature_extraction.text import CountVectorizer
from sklearn.metrics.pairwise import cosine_similarity
```

```
if not isinstance(custom_stopwords, list):
    ... custom_stopwords = list(custom_stopwords)
```

```
# TF 벡터 생성
tf_vectorizer = CountVectorizer(max_features=100, stop_words=None)
tf_X = tf_vectorizer.fit_transform(corpus_tf)
df_tf = pd.DataFrame(tf_X.toarray(), columns=tf_vectorizer.get_feature_names_out(), index=names)
```

```
# 정치인별 TF 상위 15개 단어 출력
print("정치인별 TF 상위 15개 단어:")
for name in names:
    ... top_15 = df_tf.loc[name].sort_values(ascending=False).head(15)
    ... print(f"\n[{name}]")
    ... for word, freq in top_15.items():
    ... | ... print(f"{word}: {freq}")
```

```
# 정치인별 TF 상위 15 단어 시각화
```

```
# 한글 폰트 설정 (Windows 기준)
mpl.rcParams['font.family'] = 'Malgun Gothic'
mpl.rcParams['axes.unicode_minus'] = False
```


```
for name in names:
    ... top_15 = df_tf.loc[name].sort_values(ascending=False).head(15)
    ...
    ... plt.figure(figsize=(8, 6))
    ... plt.barh(top_15.index[::-1], top_15.values[::-1], color='cornflowerblue')
    ... plt.title(f"{name} - TF 상위 15 단어")
    ... plt.xlabel("단어 빈도수")
    ... plt.tight_layout()
    ... plt.show()
```

$TF(t,d) = \text{문서 } d \text{의 전체 단어 수} / \text{해당 문서 } d \text{에서 단어 } t \text{가 등장한 횟수}$


4. 연구 진행

3-1) TF 분석


정치인별 TF(단어 빈도) 상위 15개 단어



이재명, 더불어민주당, 국민의힘, 민주당, 국민, 김문수, 지지, 이준석, 의원, 정치, 법원, 밝히, 조사, 사건, 서울



국민의힘, 김문수, 이재명, 단일, 이준석, 지지, 의원, 조사, 투표, 서울, 밝히, 기자, 한덕수, 대표




이준석, 이재명, 국민의힘, 김문수, 단일, 개혁신당, 지지, 조사, 정치, 토론, 공약, 서울, 더불어민주당, 민주당, 기자


4. 연구 진행

3-1) TF 분석


정치인별 TF(단어 빈도) 상위 15개 단어



이재명, 더불어민주당, 국민의힘, 민주당, 국민, 김문수, 지지, 이준석, 의원, 정치, 법원, 밝히, 조사, 사건, 서울



국민의힘, 김문수, 이재명, 단일, 이준석, 지지, 의원, 조사, 투표, 서울, 밝히, 기자, 한덕수, 대표




이준석, 이재명, 국민의힘, 김문수, 단일, 개혁신당, 지지, 조사, 정치, 토론, 공약, 서울, 더불어민주당, 민주당, 기자

4. 연구 진행


3-1) TF 분석

정치인별 TF(단어 빈도) 상위 15개 단어




이재명, 더불어민주당, 국민의힘, 민주당, 국민, 김문수, 지지, 이준석, 의원, 정치, 법원, 밝히, 조사, 사건, 서울

후보 개인 > 정당



국민의힘, 김문수, 이재명, 단일, 이준석, 지지, 의원, 조사, 투표, 서울, 밝히, 기자, 한덕수, 대표

후보 개인 < 정당




이준석, 이재명, 국민의힘, 김문수, 단일, 개혁신당, 지지, 조사, 정치, 토론, 공약, 서울, 더불어민주당, 민주당, 기자

후보 개인 >>>>> 정당

4. 연구 진행


3-1) TF 분석

정치인별 TF(단어 빈도) 상위 15개 단어




이재명, 더불어민주당, 국민의힘, 민주당, 국민, 김문수, 지지, 이준석, 의원, 정치, 법원, 밝히, 조사, 사건, 서울

후보 개인 > 정당



국민의힘, 김문수, 이재명, 단일, 이준석, 지지, 의원, 조사, 투표, 서울, 밝히, 기자, 한덕수, 대표

후보 개인 < 정당




이준석, 이재명, 국민의힘, 김문수, 단일, 개혁신당, 지지, 조사, 정치, 토론, 공약, 서울, 더불어민주당, 민주당, 기자

후보 개인 >>>>> 정당

4. 연구 진행

3-1) TF 분석


정치인별 TF(단어 빈도) 상위 15개 단어



이재명, 더불어민주당, 국민의힘, 민주당, 국민, 김문수, 지지, 이준석, 의원, 정치, 법원, 밝히, 조사, 사건, 서울


후보 개인 > 정당

세 후보 간 대립 구도에서 정치적 담론의 중심축



국민의힘, 김문수, 이재명, 단일, 이준석, 지지, 의원, 조사, 투표, 서울, 밝히, 기자, 한덕수, 대표

후보 개인 < 정당



이준석, 이재명, 국민의힘, 김문수, 단일, 개혁신당, 지지, 조사, 정치, 토론, 공약, 서울, 더불어민주당, 민주당, 기자

후보 개인 >>>>> 정당

4. 연구 진행

3-1) TF 분석

```
# 5. 지정된 키워드들이 함께 등장하는 문장을 추출하는 함수
def extract_sentences_with_keywords(articles, keywords, stopwords, stop_tags, sample_n=10):
    matched = []

    for article in articles:
        content = article.get("content", "")
        article_id = article.get("id", "UNKNOWN_ID")

        # 문장을 마침표/물음표/느낌표/어미 기준으로 분리
        sentence_split_pattern = r'(?<=[.?!다요])\s+'
        sentences = re.split(sentence_split_pattern, content)

        for sentence in sentences:
            # 형태소 분석: 불필요한 품사와 불용어를 제거한 단어 리스트 생성
            tokens = kiwi.tokenize(sentence)
            words = [
                tok.form for tok in tokens
                if tok.tag not in stop_tags and tok.form not in stopwords
            ]

            # 검색 키워드 중 몇 개가 문장에 등장하는지 확인
            overlap = set(words) & set(keywords)
            if all(term in words for term in search_terms):
                matched.append({
                    "sentence": sentence.strip(), # 문장 내용
                    "article_id": article_id, # 해당 문장이 포함된 기사 ID
                    "matched_words": list(overlap) # 함께 등장한 키워드 리스트
                })

    # 조건에 맞는 문장에서 최대 sample_n 개 랜덤 추출
    return random.sample(matched, min(sample_n, len(matched)))
```

```
# 7. 찾고 싶은 단어 지정 (이 리스트 안의 단어들이 모두 함께 등장하는 문장을 추출)
search_terms = ["김문수", "단일"] # 이 부분만 바꿔가며 사용하면 됩니다

# 8. 문장 추출 실행
samples = extract_sentences_with_keywords(
    articles=articles,
    keywords=search_terms,
    stopwords=stopwords,
    stop_tags=stop_tags,
    sample_n=5 # 랜덤 추출 개수
)

# 9. 결과 출력
for idx, item in enumerate(samples, 1):
    print(f"[{idx}] {item['sentence']}")
    print(f"    📄 기사 ID: {item['article_id']}")
    print(f"    🔍 함께 등장한 단어: {item['matched_words']}\n")
```

4. 연구 진행

3-1) TF 분석

김문수,
단일

[1] 또 다른 영남권 재선 의원은 “한덕수 전 국무총리와 단일화가 불발된 뒤 당에 실망한 사람이 꽤 있다”며 “이들을 투표장으로 끌어내는 게 관건”이라고 말했다.불안한 건 김문수 후보 쪽도 마찬가지다. 📄 기사 ID: 이준석_한겨레신문_20250516_4689 🔍 함께 등장한 단어: ['단일', '김문수']	
[2] 하지만 국민의힘 김용태 비상대책위원장은 이날 기자들과 만나 “단일화가 없더라도 3자 구도에서 김문수 후보가 이길 수 있다는 확신이 있다”고 말했다. 📄 기사 ID: 이준석_동아일보_20250527_3976 🔍 함께 등장한 단어: ['단일', '김문수']	
[3] ‘김문수·이준석 단일화’ 물었더니...반대 43%·찬성 38% 📄 기사 ID: 김문수_조선일보_20250514_2808 🔍 함께 등장한 단어: ['단일', '김문수']	제 21대 대선 후보군이 확정된 이후 진행된 여론조사에서 이재명 더불어민주당 후보가 50%대 지지율을 기록하며 오차범위 밖 1위를 기록했다는 결과가 14일 나왔다.
[4] 그러면서 “꼭 필요한 연락은 공보 담당이나 당 관계자를 통해 주시면 감사하겠다”고 덧붙였다.국민의힘은 최근 이준석 후보 측에 김문수 후보와의 단일화를 거듭 제안하고 있지만 이 후보는 선을 긋고 있다. 📄 기사 ID: 이준석_오마이뉴스_20250522_4110 🔍 함께 등장한 단어: ['단일', '김문수']	
[5] 사전투표가 시작되기 전까지 후보 단일화가 이뤄지면 사전투표용지의 후보자 이름에 ‘사퇴’라고 표기돼 투표자의 혼선을 막을 수 있기 때문이다.김문수·이준석 후보 지지율을 합칠 경우 이재명 후보를 넘어선다는 최근 여론조사 결과는 국민의힘을 더욱 단일화에 목매게 한다. 📄 기사 ID: 김문수_한겨레신문_20250526_3510 🔍 함께 등장한 단어: ['단일', '김문수']	


이준석,
단일

[1] 위의 갤럽 조사에서 김 후보로 단일화했을 때 이준석 후보 지지층 가운데 55%는 김 후보로 이동했지만 30%는 이재명 후보로 이탈하는 것으로 집계됐다.위의 갤럽 조사는 무선전화 면접으로 이뤄졌다. 📄 기사 ID: 김문수_경향신문_20250515_1975 🔍 함께 등장한 단어: ['단일', '이준석']	
[2] 뉴스1이 한국갤럽에 의뢰해 지난 12~13일 성인 1002명에게 3자 구도에서 지지 후보를 물은 결과(95% 신뢰수준에 ±3.1%포인트) 이재명 후보가 51%, 김 후보가 31%, 이준석 후보가 8%였다.김 후보로 단일화를 해도 이준석 후보에게 줄 보상은 뚜렷치 않다. 📄 기사 ID: 이준석_경향신문_20250515_3612 🔍 함께 등장한 단어: ['단일', '이준석']	
[3] 공동취재사인이준석 개혁신당 대통령 후보가 26일 김문수 국민의힘 후보와의 단일화 가능성은 “0%”라며 “국민의힘과 김 후보가 만약 정말 이재명 (더불어민주당) 후보를 막는 것이 중요하고 진정성이 있다면, 그냥 오늘 즉각 후보를 사퇴하면 된다”고 말했다. 📄 기사 ID: 이준석_한겨레신문_20250526_4780 🔍 함께 등장한 단어: ['단일', '이준석']	
[4] 안철수 국민의힘 공동선거대책위원장은 이날 경기 성남시 가천대에서 이준석 개혁신당 후보를 만나 김문수 국민의힘 후보와의 단일화 문제를 논의했다. 📄 기사 ID: 이준석_중앙일보_20250521_4518 🔍 함께 등장한 단어: ['단일', '이준석']	
[5] 전 대표는 “이낙연 대표가 국민의힘과의 연대나 협력에 대해 아직 특별하게 관심을 갖고 있지는 않다”며 “앞으로 논의하는 과정에서 공유점을 찾아갈 수 있지 않을까 생각한다”고 했다.이준석 후보를 향한 단일화 러브콜은 이날도 이어졌다. 📄 기사 ID: 김문수_경향신문_20250520_2032 🔍 함께 등장한 단어: ['단일', '이준석']	

4. 연구 진행

3-1) TF 분석


정치인별 TF(단어 빈도) 상위 15개 단어



이재명, 더불어민주당, 국민의힘, 민주당, 국민, 김문수, 지지, 이준석, 의원, 정치, 법원, 밝히, 조사, 사건, 서울


후보 개인 > 정당

세 후보 간 대립 구도에서 정치적 담론의 중심축



국민의힘, 김문수, 이재명, 단일, 이준석, 지지, 의원, 조사, 투표, 서울, 밝히, 기자, 한덕수, 대표

후보 개인 < 정당




이준석, 이재명, 국민의힘, 김문수, 단일, 개혁신당, 지지, 조사, 정치, 토론, 공약, 서울, 더불어민주당, 민주당, 기자

후보 개인 >>>>> 정당

4. 연구 진행

3-1) TF 분석


정치인별 TF(단어 빈도) 상위 15개 단어



이재명, 더불어민주당, 국민의힘, 민주당, 국민, 김문수, 지지, 이준석, 의원, 정치, 법원, 밝히, 조사, 사건, 서울

후보 개인 > 정당


세 후보 간 대립 구도에서 정치적 담론의 중심축
사법 리스크



국민의힘, 김문수, 이재명, 단일, 이준석, 지지, 의원, 조사, 투표, 서울, 밝히, 기자, 한덕수, 대표

후보 개인 < 정당

국민의힘 경선 과정 김문수-한덕수 단일화 이슈



이준석, 이재명, 국민의힘, 김문수, 단일, 개혁신당, 지지, 조사, 정치, 토론, 공약, 서울, 더불어민주당, 민주당, 기자

후보 개인 >>>>> 정당

대선 토론 관련, 공약(?)

4. 연구 진행

3-1) TF 분석

이재명, 법원

[1] 대법원의 이재명 더불어민주당 대선후보 상고심에 대해선 “논란이 된 대법원 판결의 대상 사건과 관련해 개별 재판과 절차 진행의 당부에 관한 의견 표명은 부적절하다”며 안건으로 채택하지 않았다. 📄 기사 ID: 이재명_중앙일보_20250521_1435 🔍 함께 등장한 단어: ['법원', '이재명']	
[2] 망치려 든다”고 했다. ‘특정인 면소법’ ‘사법부 장악법’ 민주당, 집권 땀 바로 처리 태세 📄 기사 ID: 이재명_조선일보_20250515_1082 🔍 함께 등장한 단어: ['법원', '이재명']	민주당은 지난 1일 대법원에서 이재명 후보가 불리한 판결을 받자, 하루 만인 2일 공직선거법 개정안을 발의했다.
[3] 뉴시스 황교안 무소속 대선 후보가 이재명 더불어민주당 대선 후보의 등록을 취소해달라며 낸 집행정지 신청이 법원에서 각하됐다. 📄 기사 ID: 이재명_중앙일보_20250528_1508 🔍 함께 등장한 단어: ['법원', '이재명']	
[4] 김 실장은 “국가폭력 피해자들이 지연된 정의는 정의가 아니라고 말해왔는데 대법원이 (이재명 판결에서) 선택적·선별적으로 그런 말을 썼다는 것에 피해자들은 분노하고 있다”고 했다. 쥐고 묵힌 사건들, 답답한 노동자들노동사건도 유독 심리가 오래 걸린다. 📄 기사 ID: 이재명_경향신문_20250525_301 🔍 함께 등장한 단어: ['법원', '이재명']	
[5] 그는 그 이유로 “내란음호냐 아니냐에 대한 양 지지층의 성격이 다르고 만약 단일화가 이뤄졌을 경우 야합에 대한 국민적 비판과 분노 때문”이라고 했다. 김 위원장은 대법관을 14명에서 30명까지 단계적으로 늘리고 비법조인도 대법관 임용 자격을 부여하는 법원조직법 개정안에 이재명 후보가 반대 의견을 표한 데 대해 📄 기사 ID: 김문수_한겨레신문_20250524_3495 🔍 함께 등장한 단어: ['법원', '이재명']	

이재명, 사건

[1] 어떻게 보장하나”라고 했다. 이준석 후보는 민주당이 이재명 후보의 공직선거법 위반 사건과 관련해 허위 사실 공표죄 조항 개정을 추진하는 걸 비판했다. 📄 기사 ID: 이준석_조선일보_20250519_4277 🔍 함께 등장한 단어: ['이재명', '사건']	
[2] /장려성 기자 📄 기사 ID: 이재명_조선일보_20250518_1116 🔍 함께 등장한 단어: ['이재명', '사건']	이재명 더불어민주당 대선 후보의 아내 김혜경씨가 공직선거법 위반 사건 항소심(2심)에서도 1심과 같은 벌금 150만원을 선고받자, 이에 불복해 상소했다. 18일 법조계에 따르면 김씨
[3] ▲ 더불어민주당 전현희 최고위원, 진성준 정책위의장, 추미애, 박주민 등 의원들이 2일 오후 서울 서초구 대법원앞에서 이재명 대통령후보 공직선거법 위반 혐의 사건 상고심 (유죄 취지)파기 환송 규탄 기자회견을 열었다. 📄 기사 ID: 이재명_오마이뉴스_20250514_785 🔍 함께 등장한 단어: ['이재명', '사건']	
[4] 신속한 재판만큼이나 공정한 재판, 충실한 재판이 중요하고 법관은 양심에 따라 독립해 심판해야 하기 때문이다. 하지만 분명한 것은 모든 사건이 이재명 판결처럼 신속하게 처리되지 않는 현실이다. 📄 기사 ID: 이재명_경향신문_20250525_301 🔍 함께 등장한 단어: ['이재명', '사건']	
[5] 다른 지역도 비슷한 피해 발생최근 이재명 대선캠프를 사칭한 사건이 발생하고, 실제 사실이 아닌 모텔 숙박 예약이 김해와 진주에서 벌어졌다는 것이다. 누군가가 지난 14일 김해지역 한 모텔에 '당대표 든든캠프 홍보실장 강△△'이라는 명함을 제시하면서 30명이 숙박할 방을 예약하고, 📄 기사 ID: 이재명_오마이뉴스_20250516_801 🔍 함께 등장한 단어: ['이재명', '사건']	

4. 연구 진행

3-1) TF 분석

김문수, 대표

[1] 김문수 후보는 당내 경선 후 계속됐던 단일화 변수가 사라지고 이제 보수 진영 대표 선수로 선거운동을 뛰고 있는데도 그 효과를 누리지 못하고 있다. 기사 ID: 이준석_오마이뉴스_20250515_4048 함께 등장한 단어: ['대표', '김문수']
[2] 성동훈 기자김문수 국민의힘 대선 후보가 윤석열 전 대통령 내란 우두머리 혐의 재판 변호인이자 자유통일당 비례대표 후보였던 석동현 변호사를 선거대책위원회에 영입했다. 기사 ID: 김문수_경향신문_20250514_1959 함께 등장한 단어: ['대표', '김문수']
[3] 손 전 대표는 이 자리에서 “위기의 대한민국을 살릴 사람은 김문수 뿐”이라며 김 후보 지지를 선언했다. 기사 ID: 김문수_한겨레신문_20250522_3467 함께 등장한 단어: ['대표', '김문수']
[4] 이어 “한덕수 후보로의 단일화를 시도한 의원들이 대부분 TK 국회의원들”이라며 “당원들도 당연히 한덕수로 단일화가 될 줄 알았는데 안됐기 때문에 실망감도 크지 않았겠나”라고 짚었다.그러면서 “대부분의 합리적 보수층은 과거 아스팔트를 대표했던 차명진, 송영선 이런 인사들이 김문수 캠프에 합류한 것에 대해 우려를 기사 ID: 이준석_오마이뉴스_20250514_4042 함께 등장한 단어: ['대표', '김문수']
[5] 한동훈 국민의힘 전 대표가 21일 오후 대구 중구 서문시장을 찾아 김문수 국민의힘 대통령 후보 지원 유세를 하고 있다. 기사 ID: 이재명_동아일보_20250522_581 함께 등장한 단어: ['대표', '김문수']

4. 연구 진행

3-1) TF 분석

이준석,
토론

[1] 경제 분야 주제 첫 TV토론 모두발언이준석 “이공계 출신 리더십” 권영국 “불평등 세상 갈아엎겠다”

18일 서울 마포구 SBS프리즘타워에서 열린 중앙선거방송토론위원회 주관 제21대 대통령선거 후보자토론회에서 각 정당 대선 후보들이 선전을 다짐하고 있다.
기사 ID: 이재명_조선일보_20250518_1108
함께 등장한 단어: ['토론', '이준석']

[2] 국회사진기자단 이준석 개혁신당 후보가 대선 후보 3차 TV 토론 도중 여성의 신체에 대한 폭력적 표현을 한 데 대해 사퇴 요구 등 비판이 쏟아졌다.
기사 ID: 이준석_중앙일보_20250528_4588
함께 등장한 단어: ['토론', '이준석']

[3] 2025.05.23 국회사진기자단6·3 대선을 앞두고 23일 열린 두 번째 TV 토론에서 더불어민주당 이재명 대선 후보와 국민의힘 김문수 대선 후보, 개혁신당 이준석 대선 후보가 네거티브 난타전을 펴며 정면 충돌했다.
기사 ID: 이준석_동아일보_20250523_3932
함께 등장한 단어: ['토론', '이준석']

[4] 이준석 개혁신당 후보는 전날 중앙선거방송토론위원회가 개최한 세 번째 대선 후보 TV토론에서 여성 신체를 언급한 성폭력 발언을 여과 없이 전했다.
기사 ID: 이준석_경향신문_20250528_3765
함께 등장한 단어: ['토론', '이준석']

[5] 지난 18일 첫 TV토론 당시 이준석 후보가 ‘호텔경제론’ 등으로 논란을 제기했지만 국민의힘이나 언론 탓으로 돌릴 뿐 이준석 후보를 직접 겨냥하진 않았다.
기사 ID: 이준석_중앙일보_20250525_4555
함께 등장한 단어: ['토론', '이준석']

이준석,
공약

[1] 다만 그는 10대 공약에서 ‘에너지 고속도로’를 연결해 재생에너지 활용을 제고하겠다고 했다.이준석 후보는 TV토론에서 “중국이 많이 장악한 풍력 시장”이라며 재생에너지를 ‘친중’과 연관시켰다.
기사 ID: 이재명_경향신문_20250526_320
함께 등장한 단어: ['이준석', '공약']

[2] 이준석 후보는 이재명 후보의 공약인 ‘요양병원 간병비 건강보험 급여 확대’를 언급하며 “연간 15조 원 정도의 재원은 어떻게 마련할 것이냐”고 물었다.
기사 ID: 이준석_동아일보_20250524_3936
함께 등장한 단어: ['이준석', '공약']

[3] 이준석 후보는 청년 세대의 연금 계좌를 기존 세대와 분리하는 신연금 도입, 납부 보험료에 비례해 급여를 받는 ‘확정기여형’ 연금제도 도입 등을 공약하고 있다.
기사 ID: 김문수_한겨레신문_20250526_3507
함께 등장한 단어: ['이준석', '공약']

[4] 취득세 감면하고 양도소득세 감면하고 신혼부부가 아이를 낳으면 20억 원 주택까지 양도소득세를 감면하는 내용인데 이런 게 실수요자 중심의 주택 공급인지 묻지 않을 수 없죠.”- 아무래도 이준석 후보 지지층이 2030 남성이라 거기에 타겟팅 한 거 같아요.”
기사 ID: 이준석_오마이뉴스_20250525_4140
함께 등장한 단어: ['이준석', '공약']

[5] 김 후보와 이준석 후보는 관련 공약을 제시하지 않았다.■산불, 폭염...기후재난 어쩌나후보들은 기후재난과 관련한 공약도 내놔다.
기사 ID: 김문수_경향신문_20250526_2105
함께 등장한 단어: ['이준석', '공약']

3-1) TF 분석

	이재명	김문수	이준석
개인 vs 정당	후보 개인 > 정당	후보 개인 < 정당	후보 개인 >>>>> 정당
담론 점유율	세 후보 간 대립 구도에서 정치적 담론의 중심축		
특이점	사법 리스크	국민의힘 경선 과정 김문수-한덕수 단일화 이슈	대선 토론 및 공약 관련

4. 연구 진행

3-2) TF-IDF 분석

TF-IDF: 단어가 한 문서에서 자주 등장, 동시에 전체 문서에서는 드물게 등장할수록 높은 점수를 부여
→ 어떤 단어가 얼마나 '의미 있게' 등장했는지 계산하는 방법

```
# 고유 키워드 추출 (15개)

...# 사용자 정의 불용어 설정
custom_stopwords = {"이런", "그런"}

for name in df_tfidf2.index:
    ...# TF-IDF 점수에서 다른 후보 평균을 뺀 값 → 고유성 점수
    ...dominant_words = df_tfidf2.loc[name] - df_tfidf2.drop(index=name).mean()
    ...
    ...# 불용어 제거
    ...dominant_words = dominant_words[~dominant_words.index.isin(custom_stopwords)]
    ...
    ...# 상위 15개 고유 키워드 출력
    ...print(f"\n{name}의 고유 키워드:")
    ...print(dominant_words.sort_values(ascending=False).head(15))

# 한글 폰트 설정
mpl.rcParams['font.family'] = 'Malgun Gothic'
mpl.rcParams['axes.unicode_minus'] = False

# 시각화: 정치인별 고유 키워드 상위 15개
for name in df_tfidf2.index:
    ...dominant_words = df_tfidf2.loc[name] - df_tfidf2.drop(index=name).mean()
    ...
    ...# ✅ 여기에도 불용어 제거 적용!
    ...dominant_words = dominant_words[~dominant_words.index.isin(custom_stopwords)]
    ...
    ...top_dominant = dominant_words.sort_values(ascending=False).head(15)

    ...# 시각화
    ...plt.figure(figsize=(10, 6))
    ...plt.barh(top_dominant.index[::-1], top_dominant.values[::-1], color="skyblue")
    ...plt.title(f"{name}의 고유 키워드 (TF-IDF 기준)")
    ...plt.xlabel("고유 TF-IDF 점수")
    ...plt.tight_layout()
    ...plt.show()
```

불용어 설정


정치인별 TF-IDF 기준 고유 키워드
15개씩 출력

bar chart로 시각화


4. 연구 진행

3-2) TF-IDF 분석


정치인별 TF-IDF 기준 고유 키워드 15개



이재명, 더불어민주당, 민주당, 법원, 사건, 국민, 재판, 선거법, 내란, 발언, 통합, 지역, 정치, 밝히, 의원



김문수, 국민의힘, 단일, 한덕수, 경선, 투표, 의원, 사전, 오후, 만나, 윤석열, 탄핵, 여론, 위원장, 대책




이준석, 개혁신당, 토론, 공약, tv, 토론회, 단일, 보수, 정책, 여성, 지지, 경제, 사회, 정치, 질문


4. 연구 진행

3-2) TF-IDF 분석


정치인별 TF-IDF 기준 고유 키워드 15개



이재명, 더불어민주당, 민주당, 법원, 사건, 국민, 재판, 선거법, 내란, 발언, 통합, 지역, 정치, 밝히, 의원



김문수, 국민의힘, 단일, 한덕수, 경선, 투표, 의원, 사전, 오후, 만나, 윤석열, 탄핵, 여론, 위원장, 대책



이준석, 개혁신당, 토론, 공약, tv, 토론회, 단일, 보수, 정책, 여성, 지지, 경제, 사회, 정치, 질문

3-2) TF-IDF 분석

이재명,
통합

[1]	앞서 김 의원은 전날 국회에서 기자회견을 열어 “이재명 민주당 대통령 후보만이 진영 논리를 넘어 국가 통합의 어젠다를 제시하고 있고, 직면한 국가 과제를 해결할 의지와 능력을 갖췄다고 판단한다”며 이 후보 지지를 선언했다.
...	 기사 ID: 이재명_한겨레신문_20250516_1669
...	 함께 등장한 단어: ['통합', '이재명']
[2]	각 당과 후보는 몇 마디 통합 메시지 뒤에 ‘내란 종식’과 ‘반(反)이재명’을 외치며 증오와 적대의 언사를 쏟아붓고 있다.
...	 기사 ID: 이준석_동아일보_20250512_3816
...	 함께 등장한 단어: ['통합', '이재명']
[3]	이재명 후보는 공식 선거운동 개시 다음 날인 13일 박정희 전 대통령의 고향인 경북 구미를 찾아 “박정희 정책이면 어떻고 김대중 정책이면 어떠냐”라며 ‘탈이념’과 ‘통합’을 강조했다.
...	 기사 ID: 이준석_동아일보_20250517_3867
...	 함께 등장한 단어: ['통합', '이재명']
[4]	연합뉴스.....이재명 더불어민주당 대선 후보와 김문수 국민의힘 대선 후보는 27일 중앙선거관리위원회가 주최한 대선후보 3차 TV 토론을 마친 후 기자들을 만나 ‘통합의 중요성’을 강조했다.
...	 기사 ID: 김문수_중앙일보_20250528_3250
...	 함께 등장한 단어: ['통합', '이재명']
[5]	김 후보가 자신의 사법리스크를 겨냥해 “백현동, 대장동 의혹 등 재판을 5개나 받고 있고 얼마나 많은 주변인들이 의문사했느냐”며 “거짓말과 부패를 뿌리 뽑는 것이 국민 통합의 첫 걸음”이라고 비판하자 역공을 펼친 것이다. 김 후보
...	 기사 ID: 김문수_동아일보_20250523_2375
...	 함께 등장한 단어: ['통합', '이재명']

김문수,
윤석열

[1]	이어 “국민의힘은 결국 제 손으로 내란수괴 하나 출당시키지 못한 한심한 내란 잔당으로 영원히 박제됐다”면서 “‘윤석열 인증 후보’ 김문수는 이제 무슨 수를 써도 ‘극우 내란 후보’의 굴레에서 벗어날 수 없다”고 주장했다.
	 기사 ID: 김문수_중앙일보_20250517_3126
	 함께 등장한 단어: ['김문수', '윤석열']
[2]	황 대변인은 “오늘의 탈당이야말로 내란 수괴 윤석열과 김문수 후보, 국민의힘이 모두 한 몸이고 공동운명체임을 보여주는 증거”라며 “내란수괴와 극우 내란 후보가 결별했다는 알리바이를 만들기 위해 짜고친 대국민 사기극이다.
	 기사 ID: 김문수_중앙일보_20250517_3127
	 함께 등장한 단어: ['김문수', '윤석열']
[3]	조 대표는 “윤석열과 가장 가까이 있었던 친윤석열로 불리는 김문수 후보를 선출한 그때부터 사실은 선거판은 결정됐다”며 “반대로 그때 한동훈 후보를 국민의힘이 뽑았으면 한동훈-이준석 단일화는 굉장히 힘이 있었을 것”이라고 말했다.
	 기사 ID: 이준석_한겨레신문_20250527_4790
	 함께 등장한 단어: ['김문수', '윤석열']
[4]	이어 이재명 후보는 김문수 후보를 향해 “내란 수괴 윤석열 전 대통령에 대해서 계속 비호하는 입장을 가지고 있는데 단절할 생각 혹시 없냐”라며 “전광훈과 같은 극우 세력과 단절할 생각이 없냐”고 물었다.
	 기사 ID: 김문수_중앙일보_20250523_3195
	 함께 등장한 단어: ['김문수', '윤석열']
[5]	반면 윤석열에게 투표했다는 응답자(n=2291)는 이번 대선에서는 이재명 13.5%-김문수 70.5%-이준석 12.8%로 나뉘었다.중도층(n=2225)의 선택은 이재명 50.9%, 김문수 31.5%, 이준석 13.7%로 이재명이 과반이었다.
	 기사 ID: 김문수_오마이뉴스_20250528_2687
	 함께 등장한 단어: ['김문수', '윤석열']

4. 연구 진행

3-3) TF-IDF 기반 코사인 유사도 분석

```
#정치인 간 TF-IDF 기반 코사인 유사도 분석
```

```
from sklearn.metrics.pairwise import cosine_similarity
```

```
!pip install seaborn  
import seaborn as sns
```

```
# 코사인 유사도 계산
```

```
cos_sim_matrix = cosine_similarity(df_tfidf2.values)
```

```
# 결과를 DataFrame으로 보기 좋게 정리
```

```
df_cos_sim = pd.DataFrame(cos_sim_matrix, index=names, columns=names)
```

```
print("\n[정치인 간 TF-IDF 기반 코사인 유사도]")
```


```
print(df_cos_sim)
```

```
plt.figure(figsize=(8, 6))
```

```
sns.heatmap(df_cos_sim, annot=True, cmap='Blues', fmt=".2f", linewidths=0.5)
```

```
plt.title('정치인 간 TF-IDF 기반 코사인 유사도')
```

```
plt.show()
```



Word2Vec 학습

4. 연구 진행

2) Word2Vec-학습과정 키워드 추출(이재명)

```
from gensim.models import Word2Vec

# 형태소 분석된 문장에서 단어만 추출 (ex: '라디오(NNG)' → '라디오') + 'vs' 삭제
sentences = df['tagged'].dropna().tolist()

# 제외하고 싶은 단어
ban_words = {"vs", "였고", "d", "이", "옛새", "보름", "열흘", "연이틀", "뉴스", "후보", "오마이포토", "시엔", "문수"}
ban_tags = {"VCP", "SL"}

# 필터링
tokenized_sentences = [
    [
        token.split('.')[0]
        for token in sentence.split()
        if token.split('.')[0].lower() not in ban_words and token.split('.')[0][-1:] not in ban_tags
    ]
    for sentence in sentences
]

# Word2Vec 학습 (Skip-gram, sg=1)
model = Word2Vec(
    sentences=tokenized_sentences,
    vector_size=100,
    window=5,
    min_count=3,
    sg=1,
    workers=4,
    seed=42
)

# Word2Vec에 실제 들어간 단어만 기준으로 딕셔너리 생성
word_to_tag = {}

for sentence in df['tagged'].dropna():
    for token in sentence.split():
        if "(" in token and ")" in token:
            word, tag = token.rsplit("(", 1)
            tag = tag.rstrip("(")
            # 단어가 Word2Vec 학습에 실제 포함된 경우만
            if word in model.wv and word not in word_to_tag:
                word_to_tag[word] = tag
```

Skip-gram 방식으로 학습

Vector_size = 100 > 100차원 벡터로 표현

window = 5 > 중심 단어 기준으로 몇 개의 단어를 고려할지 결정

min_count = 3 > 말뭉치에서 등장 빈도가 3미만인 단어는 학습 대상서 제외

```
# Word2Vec에 실제 들어간 단어만 기준으로 딕셔너리 생성
word_to_tag = {}

for sentence in df['tagged'].dropna():
    for token in sentence.split():
        if "(" in token and ")" in token:
            word, tag = token.rsplit("(", 1)
            tag = tag.rstrip("(")
            # 단어가 Word2Vec 학습에 실제 포함된 경우만
            if word in model.wv and word not in word_to_tag:
                word_to_tag[word] = tag

# 이재명과 유사한 단어 50개 추출

keyword = '이재명'

if keyword in model.wv:
    similar_words = model.wv.most_similar(keyword, topn=50)
    print(f"\n[{keyword}]과 유사한 단어 (품사 포함):")
    for word, sim in similar_words:
        tag = word_to_tag.get(word, "UNKNOWN") # 품사 없으면 'UNKNOWN'으로 출력
        print(f" {word} ({tag}) - {sim:.3f}")
else:
    print(f"'{keyword}' 단어가 Word2Vec vocabulary에 없습니다.")
```

이재명과 유사한 단어 키워드 추출


→

대선 (NNG)	- 0.645
결장 (NNG)	- 0.644
안방 (NNG)	- 0.643
더불어민주당 (NNP)	- 0.643
대선판 (NNG)	- 0.634
캡처 (NNP)	- 0.628
불잡 (VV-R)	- 0.625
월미도 (NNP)	- 0.625
기형 (NNG)	- 0.621
불불 (VV)	- 0.619
자전 (NNG)	- 0.617
소연 (NNP)	- 0.616
조짐 (NNG)	- 0.615
확실시 (NNG)	- 0.614
한껏 (MAG)	- 0.613
수원역 (NNP)	- 0.613
고현 (NNP)	- 0.612
파이팅 (NNG)	- 0.612
신승 (NNG)	- 0.611
맴돌 (VV)	- 0.610
물러가 (VV)	- 0.608
청각 (NNG)	- 0.608
다자 (NNG)	- 0.607
...	
미혼 (NNG)	- 0.593
유성호 (NNP)	- 0.592
김우석 (NNP)	- 0.591
한국방송협회 (NNP)	- 0.591

유사도 점수가 높은 top 50

4. 연구 진행

2) Word2Vec-클러스터링 이재명



4. 연구 진행

2) Word2Vec-학습과정 키워드 추출(김문수)

```
from gensim.models import Word2Vec

# 형태소 분석된 문장에서 단어만 추출 (ex: '라디오(NNG)' → '라디오') + 'vs' 삭제
sentences = df['tagged'].dropna().tolist()

# 제외하고 싶은 단어
ban_words = {"vs", "였고", "D", "이", "였새", "보름", "열흘", "연이를", "뉴시스", "김", "후보", "기자김지호", "뉴스브리핑"}
ban_tags = {"VCP", "SL"}

# 필터링
tokenized_sentences = [
    [
        token.split('(')[0]
        for token in sentence.split()
        if token.split('(')[0].lower() not in ban_words and token.split('(')[-1][:-1] not in ban_tags
    ]
    for sentence in sentences
]

# Word2Vec 학습 (Skip-gram, sg=1)
model = Word2Vec(
    sentences=tokenized_sentences,
    vector_size=100,
    window=5,
    min_count=3,
    sg=1,
    workers=4,
    seed=42
)

# Word2Vec에 실제 들어간 단어만 기준으로 딕셔너리 생성
word_to_tag = {}

for sentence in df['tagged'].dropna():
    for token in sentence.split():
        if "(" in token and ")" in token:
            word, tag = token.rsplit("(", 1)
            tag = tag.rstrip(")")
            # 단어가 Word2Vec 학습에 실제 포함된 경우만
            if word in model.wv and word not in word_to_tag:
                word_to_tag[word] = tag
```

Skip-gram 방식으로 학습
Vector_size = 100 > 100차원 벡터로 표현
window = 5 > 중심 단어 기준으로 몇 개의 단어를 고려할지 결정
min_count = 3 > 말뭉치에서 등장 빈도가 3미만인 단어는 학습 대상서 제외

```
# 김문수와 유사한 단어 50개 추출

keyword = '김문수'

if keyword in model.wv:
    similar_words = model.wv.most_similar(keyword, topn=50)
    print(f"₩n[{keyword}]과 유사한 단어 (품사 포함):")
    for word, sim in similar_words:
        tag = word_to_tag.get(word, "UNKNOWN") # 품사 없으면 'UNKNOWN'으로 출력
        print(f" {word} ({tag}) - {sim:.3f}")
else:
    print(f"'{keyword}' 단어가 Word2Vec vocabulary에 없습니다.")
```


김문수와 유사한 단어 키워드 추출

김동연 (NNP)	- 0.610
으능정이거리 (NNP)	- 0.606
국민의힘 (NNP)	- 0.597
하우스 (NNP)	- 0.596
혹평 (NNG)	- 0.593
추첨 (NNG)	- 0.593
삼자 (NNG)	- 0.593
수비 (NNG)	- 0.589
들뜨 (VV)	- 0.587
김재연 (NNP)	- 0.585
호의 (NNG)	- 0.583
더블 (NNG)	- 0.583
스코어 (NNG)	- 0.579
관전 (NNG)	- 0.575
급속히 (MAG)	- 0.575
팽팽 (XR)	- 0.575
기쁘 (VA)	- 0.575
김홍국 (NNP)	- 0.574
파전 (NNG)	- 0.573
총집결 (NNG)	- 0.572
컨퍼런스 (NNG)	- 0.572
울산광역시 (NNP)	- 0.571
제주시 (NNP)	- 0.571
영천역 (NNP)	- 0.571
개비 (NNG)	- 0.571
총합 (NNG)	- 0.569
신림 (NNP)	- 0.569
民 (SH)	- 0.568
이어서 (MAG)	- 0.568
스윙 (NNG)	- 0.567
캡처 (NNP)	- 0.567
미디어데이 (NNG)	- 0.566
대선 (NNG)	- 0.566
결장 (NNG)	- 0.565
정면충돌 (NNG)	- 0.565
거머쥐 (VV)	- 0.564
패싱 (NNP)	- 0.564
院外 (SH)	- 0.563
오른쪽 (NNG)	- 0.563
경합 (NNG)	- 0.563
밀어주 (VV)	- 0.562

유사도 점수가 높은 top 50

4. 연구 진행

2) Word2Vec-클러스터링 김문수



2) Word2Vec-학습과정 키워드 추출(이준석)


Skip-gram 방식으로 학습
Vector_size = 100 > 100차원 벡터로 표현
window = 5 > 중심 단어 기준으로 몇 개의 단어를 고려할지 결정
min_count = 3 > 말뭉치에서 등장 빈도가 3미만인 단어는 학습 대상서 제외

이준석과 유사한 단어 키워드 추출

유사도 점수가 높은 top 50

4. 연구 진행

2) Word2Vec-클러스터링 이준석



4. 연구 진행

2) Word2Vec-의미 결속력 측정

의미 결속력이란?
유사 단어들 간의 평균 코사인 거리로 계산하여 해당 수치가 낮을수록 의미망이 응집 일관성 있다 . 반면 수치가 높을수록 의미적 분산이 크고 다양한 맥락에서 거론될 가능성이 있다.

기준 코퍼스	이재명	김문수	이준석
이재명	0.2323	0.2242	<u>0.2678</u>
김문수	<u>0.2586</u>	0.2285	0.2324
이준석	0.2039	0.2968	<u>0.1907</u>

이재명은 정치적 중심축으로서 다양한 인물들과의 대립과 비교 속에서 의미망이 확장

김문수는 정당의 배경 속에서 여러 이슈와 얽혀 다소 파편적으로 등장

이준석은 상대적으로 자신을 중심으로 한 명확한 메시지와 개인 브랜딩이 뚜렷한 의미 구조

5. 분석 결과 요약

후보	주요 키워드 경향	보도 양상 및 특징
이재명	법원, 사건, 내란, 통합 등 고유 키워드 뚜렷	높은 TF, 의미망 응집도 → 선명한 이미지 형성 사법 리스크 + 통합 키워드 동시 등장
김문수	국민의힘, 단일, 한덕수, 탄핵 등	정당 중심 보도 ‘단일화’ 관련 키워드 다수 이재명 중심성에 상대적으로 종속
이준석	토론, 여성, tv, 질문 등	후보 개인 중심 보도 ‘단일’, ‘개혁신당’ 함께 등장 TV토론 이슈 반영

이재명 → 중심축, 독립된 의미망

김문수, 이준석 → 보수 진영 내 유사 키워드 & 중첩 프레임 → 표 분산 가능성

6. 결론

연구 요약

- TF 및 TF-IDF 분석: 이재명 후보가 세 후보의 대립 구도 내에서 중심축
- Word2Vec 분석: 이재명 중심 의미망의 구조가 명확하고 응집력 있음
- 의미망 구조 차이 등은 이재명 후보의 상대적으로 높은 당선 가능성 시사

의의 및 함의

- 유사 프레임 간 정치인 이미지 중첩 확인
- 김문수-이준석: 유사 키워드 & 클러스터 → 보수 표 분산 가능성 시사
- 언론 담론 구조로 당선 가능성 추론 가능
- 당선 후보의 의미망이 더 응집되어 있었던 점에서, 텍스트 마이닝 기반 담론 분석의 예측 가능성

6. 결론

한계

- 후보의 다양성 측면: 권영국 후보 포함
- 데이터 기간 및 규모: 4월 27일(경선) ~ 5월 28일(사전 투표 전날)까지로 확대

추후 과제

- 언론사들의 정치적 성향에 따른 후보별 프레이밍 차이
- 감성 사전 기반 분석: 보도 키워드에 부정/긍정 정서 점수 부여 → 언론 태도 분석 가능
- 의미역 분석 도입: 긍/부정 감성이 뚜렷하게 드러난 문장을 중심으로 의미역 분석
- 유권자 언어 데이터 결합: 댓글·SNS 등과 언론 담론을 함께 분석해 여론 형성 과정 추적 및 당선 결과 예측 활용

7. 참고 문헌

[1] 양혜승, 양수연. (2022). OECD 통계는 우리 사회와의 비교 잣대로 어떻게 활용되고 있는가: OECD가 인용된 언론보도에 대한 텍스트 마이닝 분석

언론 프레임 분석을 위한 텍스트 마이닝 기법 참조

[2] 이한준. (2023). 한국 언론은 어떻게 신생 대통령 권력을 정당화하는가: 막스 베버 정치지도자론과 텍스트 마이닝 분석

언론 보도 분석 및 의미 연결망 접근 참고